

컴퓨터비전 프로젝트 중간 발표

Text-Conditioned Lightweight Navigation World Model

저해상도 visual world modeling에서
텍스트 기반 semantic 주입효과 검증

곽건

Soongsil University

Navigation World Model (CVPR 2025)

- 이미지 + action(상대적 위치변화, 회전변화) + time
- CDiT에 입력
- 다음 이미지 생성

navigation action and time

$(\Delta x, \Delta y, \Delta \phi, k)$



Conditional
Diffusion
Transformer


model output



(a) navigation world model

Navigation World Models


Amir Bar¹ Gaoyue Zhou² Danny Tran³ Trevor Darrell³ Yann LeCun^{1,2}
¹FAIR at Meta ²New York University ³Berkeley AI Research



arXiv:2412.03572v2 [cs.CV] 11 Apr 2025

Figure 1. We train a Navigation World Model (NWM) from video footage of robots and their associated navigation actions (a). After training, NWM can evaluate trajectories by synthesizing their videos and scoring the final frame’s similarity with the goal (b). We use NWM to plan from scratch or rank experts navigation trajectories, improving downstream visual navigation performance. In unknown environments, NWM can simulate imagined trajectories from a single image (c). In all examples above, the input to the model is the first image and actions, then the model auto-regressively synthesizes future observations. Click on the image to view examples in a browser.

NWM (CDiT) 구조



- **Input**
 - **Future State**(노이즈 상태에서 시작)
 - **Conditioning**(action, time)
 - **Context States**(과거 프레임 이미지)
- **Output**
 - 노이즈가 제거된 **Future State**

... 그리고 계속 반복!

Problem

- 고해상도 이미지와 큰 모델에 의존해서 추론 비용이 큼
- 저해상도로 줄이면 장면의 **semantic** 정보가 쉽게 사라짐
- 긴 **rollout**에서는 작은 예측 오류가 누적되어 **drift, hallucination**이 생김
- **OOD** 환경에서는 **visual context**만으로 장면 구조를 안정적으로 이해하기 어려움

Limitations

One common failure, especially in unknown environments is mode collapse, where the model slowly generates frames that are more similar to the training data.



Core Idea

- 이미지만으로 부족한 장면 의미를 텍스트가 압축적으로 보완
 - 예를 들어 이미지에서는 흐릿하게 보이는 구조도 텍스트로는 “앞에 열린 길”, “오른쪽에 장애물”, “좌측으로 이어지는 통로” 처럼 명확하게 표현
- 텍스트가 **policy**를 직접 결정하는 게 아니라, **NWM**이 미래 프레임을 생성할 때 참고하는 **semantic prior** 역할

Mechanism / Insight

1. 오프라인에서 **RECON** 프레임에 대해 **Qwen** 같은 **VLM**으로 **caption** 생성
2. **caption**을 정제한 뒤 **CLIP text encoder**로 **embedding** 변환
3. 이 **text embedding**을 **NWM**의 **conditioning stream**에 추가
4. **CDiT**가 **image context**, **action**, **time/delta**, **diffusion timestep**과 함께 **text condition**을 사용해 미래 **latent**를 예측
5. **VAE decoder**로 미래 이미지를 복원
6. **rollout**이나 **planning**에서는 이 예측 결과를 **trajectory** 평가에 사용

Qwen Image Caption 생성 (Qwen2-VL-7B-Instruct)



trajectory: jackal_2019-08-08-17-49-25_1_r00

frame_time: 0

raw_caption: The scene features a grassy area with scattered leaves, a pathway, and a few buildings in the background, under a clear sky.

clean_text: a grassy area with scattered leaves, a pathway, and a few buildings in the background, under a clear sky



trajectory: jackal_2019-08-08-17-49-25_1_r00

frame_time: 10

raw_caption: The scene shows a grassy area with a pathway leading to a house, surrounded by trees and other buildings in the background.

clean_text: a grassy area with a pathway leading to a house, surrounded by trees and other buildings in the background

Evaluation

1. **Future Frame Prediction**
 - a. LPIPS, DreamSim, FID 비교
2. **Autoregressive Rollout**
 - a. 긴 rollout에서 text condition이 drift를 줄이는지 확인
3. **Planning Evaluation**
 - a. ATE, RPE 같은 trajectory metric으로 실제 planning 품질 확인
4. **Lightweight / Low-resolution Evaluation**
 - a. 텍스트가 저해상도 손실을 보완하는가 ?
5. **OOD Generalization**
 - a. 텍스트가 새로운 환경에서 semantic stability를 주는가 ?

- **Baseline No-Text{원본모델} 과 224 Text에 성능비교**
- **128 No-Text와 128 Text의 성능비교**

실험	image_size	latent_size	Latent 형태 (C, H, W)
224 (nwm_cdit_s)	224	28	(4, 28, 28)
128 (nwm_cdit_s_recon_128)	128	16	(4, 16, 16)

CDiT에서 patch_size=2이므로 패치 수는 :

실험	$\text{num_patches} = (\text{latent_size} / \text{patch_size})^2$
224	$(28/2)^2 = 196$
128	$(16/2)^2 = 64$

먼저 평가지표에 대한 설명

- time

같은 현재 context에서, 각 horizon을 "직접 한 번에" 예측

[t] —————▶ [t+1s]

[t] —————▶ [t+2s]

[t] —————▶ [t+4s]

특징: 1s, 2s, 4s 예측이 서로 독립적. 이전 예측을 다시 넣지 않음.

- rollout 4fps

0.25초씩 autoregressive rollout

[t] —▶ [t+0.25] —▶ [t+0.50] —▶ [t+0.75] —▶ [t+1.0] —▶ ...
 pred1 pred2 pred3 pred4

평가 예:

1s = 4번째 예측

2s = 8번째 예측

4s = 16번째 예측

먼저 평가지표에 대한 설명

- 3) rollout_1fps

1.0초씩 autoregressive rollout

pred1

pred2

pred3

pred4

평가 예:

1s = 1번째 예측

2s = 2번째 예측

- 한줄요약

time: “현재에서 4초 뒤를 바로 맞출 수 있나?”

rollout_1fps 4s: 1초 예측을 4번 연속 수행한 뒤 마지막 프레임 평가

- 셋다 필요한 이유

time은 누적오차가 없어서 “순수 horizon 예측 능력”

rollout_4fps는 실제 달한 루프에 가까운 촘촘한 누적오차

LPIPS, DreamSim, FID의 차이

- 생성 이미지가 GT와 얼마나 다른가
- **LPIPS**
 - 두 이미지를 1:1로 비교하는 perceptual distance. CNN feature 공간에서 얼마나 다른지 봄. 샘플별 대응쌍이 필요.
- **DreamSim**
 - 두 이미지를 1:1로 비교하는 perceptual distance, 최근의 representation을 써서 “사람이 느끼는 유사성”에 더 맞추려는 계열. 역시 대응쌍이 필요.
- **FID**
 - 개별 이미지 쌍을 직접 비교하지 않고,
 - 생성 이미지 집합과 GT 이미지 집합의 분포 차이를 봄. 전체 샘플의 품질과 다양성을 같이 보는 데 더 가까움. 대응쌍이 없어도 계산 가능.

LPIPS = AlexNet

DreamSim = 기본 ensemble = DINO ViT-B/16 + CLIP ViT-B/16 + OpenCLIP ViT-B/16

LPIPS, DreamSim, FID의 차이


- 공통점: 낮을수록 좋고, 생성 품질 평가용 지표
- LPIPS/DreamSim: “이 예측 한 장이 GT 한 장과 얼마나 비슷한가?”
- FID: “예측 이미지들의 전체 분포가 GT 분포와 얼마나 비슷한가?”

결과 plots

RECON Metrics: 224 Baseline No-Text vs Text

Lower is better. FID panels use log scale, long-horizon differences readable.

224
원본모델
vs 224
텍스트주
입모델




결과 plots

RECON Metrics: 128 Baseline No-Text vs Text @ 30k

Lower is better. FID panels use log scale for long-horizon differences readable.

128
해상도
축소 모델
vs
128
텍스트주
입 모델






Step 별 성능 변화

RECON Time Metrics Across Checkpoints

Lower is better. Each line tracks a horizon across training steps.

학습 step
이
증가함에
따라
3대 지표
모두 하락




추후 진행 상황

- 추후 진행 예정
 - 주입 텍스트를 다양하게 해보기
 - 텍스트 모델 (장황, 짧게, 수치를 주입하는 방식)
 - RGB -> 흑백처리?
 - 유독 어떤 상황에서 텍스트 주입의 성능이 안좋은지 확인하기
 - 네비게이션 성능에 대해서도 평가하기
 - 이미지 생성 성능이 좋아졌다면 네비게이션도 좋아졌을까?
 - 아직 네비게이션 성능 측정 방법은 알아보는 중
 - 코드 리팩토링

- **ATE — Absolute Trajectory Error**
 - 최종적으로 전체 경로가 실제 경로와 얼마나 떨어져 있냐
 - 내 모델이 카메라/로봇이 어디서 어디로 움직였는지 얼마나 정확히 맞혔는지
- **RPE — Relative Pose Error**
 - 짧은 구간에서의 상대 이동 오차
 - 1초 전 위치에서 지금 위치로 이동한 양을 제대로 예측하는지

네비게이션 성능 측정

RECON Planning Metrics: Text vs No-Text (CDiT-S, N32/K5/OPT1/rep1)



- 왜 네비게이션 성능이 떨어졌는지
- 이미지 생성 성능은 좋아졌지만 , 네비게이션 성능이 안좋아졌다 .
- 프롬프트에 위치정보가 더해져야할지 ?
- 위치정보 **RAG?**
 - 현재 위치를 기반으로 검색하면 텍스트정보를 주는 ...