

Text-Conditioned NWM Post-0427 Training & Evaluation

CDiT-S/B, 128/224, text-dense variants, frame prediction and CEM planning results

Best local ATE

1.162

CDiT-B 224 No-Text

Best local RPE

0.354

CDiT-B 224 Text

Paper NWM

1.13 / 0.35

ATE / RPE reference

Main finding

Text $\neq$ ATE

semantic gain, geometry gap

0427 이후 무엇을 했나

0427 자료의 핵심 질문 : 저해상도 visual world model 에서 텍스트가 semantic prior 로 작동하는가 .

이후 CDiT-S 뿐 아니라 CDiT-B 까지 확장해 128/224, No-Text/Text-Dense 조합을 평가했다 .

평가는 future-frame prediction 과 navigation planning 으로 나뉘었다 .

원 논문 NWM 의 RECON 지표를 기준으로 넣어 , 논문 대비 현재 위치를 수치로 비교했다 .

0427

idea + early
prediction eval

After

S/B training
128/224 variants

Now

frame + planning
paper comparison

결론 축

Text 는 frame metric 에서 자주 이득을 보인다 .

Planning ATE 는 그 이득을 그대로 따라오지 않는다 .

CDiT-B 는 S 보다 yaw/RPE 개선이 더 일관적이다 .

원 논문의 NWM 기준선

NWM 은 과거 관측과 navigation action 을 조건으로 미래 관측을 생성하는 controllable video generation model 이다 .

CDiT 는 context frame 수에 대해 선형 복잡도를 갖도록 설계되었다 .

논문은 image metric, video distribution metric, navigation metric 을 함께 보고한다 .

우리 비교에서는 현재 재현 가능한 LPIPS/DreamSim/FID 와 ATE/RPE 에 초점을 맞춘다 .

Metric	Paper best/reference
4s LPIPS	0.295 action+time
4s DreamSim	0.091 action+time
4s PSNR	15.343 action+time
Planning ATE	1.13 NWM only
Planning RPE	0.35 NWM only
16s FVD	200.969 NWM

우리 실험 매트릭스

Family	Resolution	Condition	Checkpoint	Evaluated
CDiT-S	224	No-Text	nwm_cdit_s/0100000	Frame + planning
CDiT-S	224	Text Dense	nwm_cdit_s_recon_raw_text_dense/ 0030000	Frame + planning
CDiT-S	128	No-Text	nwm_cdit_s_recon_128/0030000	Frame + planning
CDiT-S	128	Text Dense	nwm_cdit_s_recon_128_text_dense/ 0030000	Frame + planning
CDiT-B	224	No-Text	nwm_cdit_b/0100000	Frame + planning
CDiT-B	224	Text Dense	nwm_cdit_b_recon_raw_text_dense/ 0030000	Frame + planning
CDiT-B	128	No-Text	nwm_cdit_b_recon_128/0030000	Frame + planning
CDiT-B	128	Text Dense	nwm_cdit_b_recon_128_text_dense/ 0030000	Frame + planning

Source: local checkpoint and planning artifact names.

평가 설정과 비교 범위

Future-frame prediction

4 초 및 16 초 rollout horizon 에서 LPIPS, DreamSim, FID 를 측정했다 .

모든 지표는 낮을수록 좋다 .

현재 산출물에는 PSNR/FVD 가 없어 논문 Table 1/6 과는 부분 비교만 가능하다 .

Planning

RECON 100-sample planning eval, CEM N32/K5/OPT1/rep1.

ATE, RPE trans, position error, yaw error 를 본다 .

논문 standalone planning appendix 의 N=120 후보 설정과 완전히 동일한 조건은 아니다 .

Future-frame prediction: CDiT-S

Variant	lpips4	dream4	fid4	lpips16	dream16	fid16
CDiT-S 128 No-Text	0.308	0.199	33.025	0.403	0.263	38.088
CDiT-S 128 Text	0.292	0.189	33.420	0.387	0.250	36.693
CDiT-S 224 No-Text	0.370	0.161	33.993	0.463	0.229	40.389
CDiT-S 224 Text	0.366	0.159	33.075	0.458	0.224	38.186

128 Text 는 LPIPS/DreamSim 에서 4s 와 16s 모두 개선된다 .

224 Text 도 S 에서는 frame metric 이 전반적으로 개선된다 .

하지만 뒤의 planning 결과에서는 S text 가 ATE 를 낮추지는 못한다 .

Future-frame prediction: CDiT-B

Variant	lpips4	dream4	fid4	lpips16	dream16	fid16
CDiT-B 128 No-Text	0.270	0.163	29.580	0.380	0.229	33.615
CDiT-B 128 Text	0.262	0.156	28.943	0.367	0.219	33.788
CDiT-B 224 No-Text	0.324	0.121	27.607	0.431	0.187	32.768
CDiT-B 224 Text	0.338	0.124	28.436	0.439	0.189	31.988


128 Text 는 B 에서도 LPIPS/DreamSim 개선이 유지된다 .
224 Text 는 LPIPS/DreamSim 이 소폭 나빠지고 , 16s FID 만 개선된다 .
B 는 absolute frame metric 이 S 보다 낮지만 , text 효과 방향은 해상도별로 다르다 .

Text minus No-Text

Text 효과 : frame metric delta

Negative is better because all metrics are lower-is-better.

Text minus No-Text: frame prediction delta



저해상도 128에서는 S/B 모두 text가 주요 perception metric을 낮춘다.

224에서는 S와 B의 방향이 갈라진다.


FID는 horizon과 모델 크기에 따라 덜 안정적이다.

Negative percent means improvement because all listed frame metrics are lower-is-better.


Checkpoint-wise rollout trend

RECON Time Metrics Across Checkpoints

Lower is better. Each line tracks a horizon across training steps.


CDiT-S checkpoint sweep
RECON CDiT-B Time Metrics Across Checkpoints

Lower is better. Each line tracks a horizon across training steps.


CDiT-B checkpoint sweep

Planning 평가 : 0427 이후 추가된 핵심 축

0427 자료에서는 future-frame metric 중심이었다 .

이후 CEM planning 평가를 추가해 생성 품질이 navigation 성능으로 이어지는지 확인했다 .

ATE/RPE 는 실제 궤적과 예측 궤적의 geometry 를 본다 .

Position/Yaw error 를 함께 보면 text 가 방향 단서를 stabilizing 하는지 분리해서 볼 수 있다 .

Metric	Interpretation
ATE	global trajectory mismatch
RPE trans	local transition error
Position	goal/pose position mismatch
Yaw	heading mismatch


Planning results: CDiT-S

Res	Cond	ATE	RPE	Pos	Yaw	Time
128	No-Text	1.280	0.378	1.989	0.375	0.74h
128	Text	1.341	0.379	2.017	0.306	0.75h
224	No-Text	1.169	0.357	1.758	0.327	1.00h
224	Text	1.248	0.371	1.880	0.376	2.56h

224 No-Text 가 S 에서 ATE/RPE 기준 최선이다 .

128 Text 는 yaw 를 18.3% 낮추지만 ATE 는 4.7% 증가한다 .

224 Text 는 frame metric 은 좋아졌지만 planning ATE/RPE/Pos/Yaw 가 모두 악화된다 .




Planning results: CDiT-B

Res	Cond	ATE	RPE	Pos	Yaw	Time
128	No-Text	1.259	0.365	1.881	0.289	1.20h
128	Text	1.261	0.358	1.823	0.250	1.19h
224	No-Text	1.162	0.355	1.718	0.315	3.17h
224	Text	1.261	0.354	1.795	0.235	2.03h


128 Text 는 ATE 가 거의 동일하고 RPE/Pos/Yaw 가 모두 개선된다 .

224 Text 는 ATE/Pos 는 악화되지만 RPE/Yaw 는 개선된다 .

B 는 S 보다 yaw 개선이 일관적이며 , best ATE 는 224 No-Text 다 .



CDiT-S 와 경향성은 유사한가



큰 방향은 유사하다 : text 가 frame metric 을 개선해도 planning ATE 가 자동으로 좋아지지는 않는다 .



차이는 B 에서 더 선명하다 : B 는 RPE/Yaw 개선이 더 일관적이고 128 에서는 Pos 도 개선된다 .

해상도 경향도 유사하다 : 224 No-Text 가 ATE 최선인 반면 , text 는 방향 /semantic 단서에는 더 잘 작동한다 .

따라서 text conditioning 은 semantic prior 로는 유효하지만 metric geometry 보강은 별도 축으로 봐야 한다 .

원 논문 대비 : planning

Planning metrics vs. NWM paper reference



논문 NWM only: ATE 1.13, RPE 0.35.


우리 best ATE 는 B 224 No-Text 1.162 로 paper 대비 +2.8%.

우리 best RPE 는 B 224 Text 0.354 로 paper 대비 +1.2%.

Text variant 는 대체로 paper ATE 까지는 못 내려간다 .

CEM budget ablation: paper-style N120/rep3

Paper-style CEM planning comparison



N120/rep3 는 모델 재학습이 아니라 CEM planning search budget 변경이다 .



Full N120/rep3 완료 : 3/3.

Best N120 ATE: CDiT-B 224 No-Text = 1.130 (-0.0% vs paper).

Best N120 RPE: CDiT-B 128 Text = 0.344 (-1.7% vs paper).

원 논문 대비 : 4 초 future-frame metric

Frame prediction vs. NWM paper reference




논문 action+time: LPIPS 0.295, DreamSim 0.091.

B 128 Text 는 LPIPS 0.262 로 paper reference 보다 낮다 .

DreamSim 은 모든 local variant 가 paper reference 보다 높다 .

PSNR/FVD 가 아직 없어 image/video 분포 비교는 미완성이다 .

Runtime 과 비용



128 planning 은 대략 0.74-1.20 시간 범위다 .

224 planning 은 설정 / 모델에 따라 1.00-3.17 시간까지 증가한다 .

논문 Table 8 은 단일 trajectory simulation runtime 이므로 여기서의 full eval total time 과 직접 비교하면 안 된다 .

Time skip, distillation, quantization 은 paper-style runtime 최적화 후보로 남아 있다 .

해석 : text 는 semantic prior, geometry 는 별도 문제

What text helps

low-res visual ambiguity
semantic object/scene prior
heading/yaw cues in B

What text misses

metric position
local obstacle geometry
consistent long-horizon state

Implication

better image metrics do not
guarantee better ATE
planning objective needs
geometry-aware conditioning
text should be fused with
pose/RAG, not used alone

다음 실험 제안

S planning 을 B 와 동일한 repeat sampler path 로 재실행해 sampler 차이를 제거한다 .

PSNR/FVD 를 추가해 논문 Table 1/6 과 더 가까운 비교 축을 만든다 .

Prompt ablation: short/full/numeric/landmark caption 을 분리해 text 효과의 원인을 좁힌다 .

Position-aware text 또는 retrieval-augmented context 를 넣어 semantic prior 에 metric geometry 를 결합한다 .

Text 가 yaw 를 낮추지만 ATE 를 높이는 route 를 failure slice 로 모아 rollout 을 시각 점검한다 .

Paper runtime 최적화 경로에 맞춰 time skip, distillation, 4-bit quantization 을 따로 측정한다 .